数据集划分策略说明

淘宝用户行为分析项目

1. 概述

数据集划分是机器学习项目中至关重要的环节，直接影响模型的泛化能力和预测效果。本说明详细阐述淘宝用户行为分析项目中的数据集划分策略，包括时间划分原则、样本构造方法、正负样本配比等关键设计决策。

本项目采用基于时间序列的数据划分策略，确保训练集和测试集在时间维度上严格分离，模拟真实场景下的预测任务。

2. 数据时间范围

2.1 原始数据时间分布

根据数据分析，原始数据的时间分布如下：

指标	数值
数据起始时间	2014-11-18 00:00:00
数据结束时间	2014-12-18 23:00:00
总天数	31 天
有购买的日期数	31 天

表 1：原始数据时间分布

2.2 行为类型分布

原始数据中各类行为的分布情况：

行为类型	数量	占比
浏览 (behavior_type=1)	11,550,581	94.3%
收藏 (behavior_type=2)	242,556	2.0%
加购 (behavior_type=3)	342,171	2.8%
购买 (behavior_type=4)	117,954	1.0%

表 2：行为类型分布

3. 时间划分策略

3.1 划分原则

本项目采用以下时间划分原则：

1. **时间顺序原则**：训练集数据必须严格早于测试集数据，模拟真实预测场景
2. **滑动窗口原则**：训练集采用最近 14 天的数据，保证数据的时效性
3. **单日测试原则**：测试集使用单日（2014-12-18）的购买行为作为预测目标

3.2 具体划分方案

训练集

时间范围：2014-12-04 00:00:00 至 2014-12-17 23:59:59

数据天数：14 天

记录数：5,924,307 条

> 用途：特征工程、模型训练
>
> **测试集**
>
> 时间范围：2014-12-18 00:00:00 至 2014-12-18 23:59:59
>
> 数据天数：1 天
>
> 记录数：3,523 条（仅购买行为）
>
> 用途：模型评估、效果验证

4. 样本构造策略

4.1 正样本构造

正样本定义为测试集中发生购买行为的用户-商品对。从测试集提取购买行为，去重后得到正样本，数量限制为 5000 个（保证训练效率）。实际正样本数为 3,151 个。

4.2 负样本构造

负样本采用以下策略生成：

4. **用户匹配**：负样本用户必须与正样本用户相同，保证用户分布一致
5. **候选池定义**：用户在训练集中浏览过但未购买的商品
6. **采样比例**：每个正样本对应 3 个负样本（1:3 配比）

4.3 样本统计

样本类型	数量	说明
正样本	3,151	测试集购买行为

样本类型	数量	说明
负样本	9,388	训练集浏览未购买
总计	12,539	正负比例约 1:3
涉及用户	1,552	去重用户数

表 3：样本统计信息

5. 划分验证

5.1 时间边界验证

验证训练集和测试集在时间维度上无重叠：

验证项	结果
训练集最大日期	2014-12-17（早于测试集）
测试集日期范围	2014-12-18（单日）
正负样本用户一致性	通过（负样本用户来自正样本）
负样本候选池	训练集浏览但未购买

表 4：样本分布验证

6. 设计合理性分析

6.1 时间窗口选择

选择 14 天作为训练窗口的原因：

- 用户行为具有周期性，14 天约等于两周，能覆盖完整的周中/周末模式
- 数据时效性，太久的历史数据可能无法反映当前用户偏好
- 计算效率，过大的窗口会增加特征计算时间

6.2 正负样本配比

选择 1:3 正负样本配比的原因：

- 类别平衡，避免模型偏向多数类
- 实际场景模拟，用户浏览但未购买的商品远多于购买的商品
- 计算效率，过多的负样本会增加训练时间

6.3 潜在问题与改进

> ⚠ **数据泄露风险：**当前实现中，负样本是从训练集中浏览但未购买的商品中采样。如果测试集中的商品在训练集中从未出现，模型将无法预测。改进方案：引入冷启动处理机制。
>
> ⚠ **时间偏移问题：**测试集使用单日数据，可能受到特殊日期（如促销日）影响。改进方案：使用多天的测试集取平均，或进行时间交叉验证。

7. 总结

本项目采用基于时间序列的数据集划分策略，主要特点包括：

7. **严格时间分离**：训练集（2014-12-04 至 12-17）和测试集（2014-12-18）在时间维度上无重叠
8. **滑动窗口设计**：使用最近 14 天数据作为训练集，保证数据时效性
9. **分层采样**：正样本 3,151 个，负样本 9,388 个，正负比例约 1:3

10. **用户匹配**：负样本用户与正样本用户一致，保证用户分布均匀

该划分策略能够有效模拟真实场景下的预测任务，同时保证训练效率和模型泛化能力。