模型评估报告

一、基础信息

项目名称	淘宝用户行为预测
任务类型	二分类
模型名称	1.Logistic Regression (主模型) 2.XGBoost (对比模型，n_estimators=200, max_depth=6)
输入特征	40 个数值型特征 类型：int/float 混合 维度：用户特征(8) + 商品特征(8) + 交互特征(12) + 类目特征(7) + 偏好特征(5)

输入特征清单

维度	特征名	业务含义	数据类型	重要性
用户特征(8个)	u_purchase_rate	用户历史购买率（购买次数/总行为数）	float	0.0559
	u_purchase_count	用户历史累计购买次数	int	0.0086
	u_total_actions_3d	用户近 3 天活跃次数	int	0.0108
	u_total_actions_7d	用户近 7 天活跃次数	int	0.0194
	u_total_actions_14d	用户近 14 天活跃次数	int	0.0159
	u_total_actions_21d	用户近 21 天活跃次数	int	0.0124
	avg_interval	用户平均购买间隔天数	float	0.0188

维度	特征名	业务含义	数据类型	重要性
商品特征(8个)	ui_last_action_hour	用户最后行为时间（小时）	int	0.0110
	i_cart_count	商品被加购次数	int	0.0244
	i_cart_to_buy_rate	商品加购转购买率	float	0.0290
	i_fav_to_buy_rate	商品收藏转购买率	float	0.0133
	i_browse_to_buy_rate	商品浏览转购买率	float	0.0058
	i_unique_users	商品独立访客数（去重）	int	0.0051
	i_hot_hour	商品热门访问时段	int	0.0047
	i_act_total_1d	商品近 1 天总互动量	int	0.0122
	i_act_total_14d	商品近 14 天总互动量	int	0.0062
交互特征(12个)	ui_funnel_score	用户-商品漏斗得分（加权行为序列）	float	0.2256
	ui_attention_intensity	用户对该商品的关注强度	float	0.1030
	ui_recent_action_concentration	近期行为集中度（近 3 天行为占比）	float	0.0477
	ui_days_since_last_action	距上次交互天数	int	0.0307
	ui_recent_3d	近 3 天交互次数	int	0.0142
	ui_view_frequency	用户对该商品浏览频率	float	0.0082
	ui_total_actions	用户-商品总交互次数	int	0.0054
	ui_time_from_first_view	首次浏览距今小时数	float	0.0044

维度	特征名	业务含义	数据类型	重要性
	ui_popularity_preference_score	商品热度与用户偏好匹配度	float	0.0066
	c_browse_to_buy_rate	类目浏览转化率（作为交互背景）	float	0.1708
	c_fav_to_buy_rate	类目收藏转化率	float	0.0190
	c_cart_to_buy_rate	类目加购转化率	float	0.0069
	c_browse_count	类目被浏览次数	int	0.0037
	c_purchase_count	类目被购买次数	int	0.0070
	c_cart_count	类目被加购次数	int	0.0054
类目特征(7个)	c_act_total_1d	类目近 1 天活跃度	int	0.0061
	c_act_total_3d	类目近 3 天活跃度	int	0.0045
	c_act_total_7d	类目近 7 天活跃度	int	0.0050
	c_popularity_rank	类目热度排名	int	0.0066
	uc_preference_score	用户对类目的偏好得分	float	0.0105
	uc_browse_count	用户在该类目下的浏览次数	int	0.0111
偏好特征(5个)	uc_total_actions	用户在该类目下的总行为数	int	0.0064
	c_act_total_14d	类目近 14 天活跃度（反映用户近期偏好类目）	int	0.0067
	c_act_total_21d	类目近 21 天活跃度	int	0.0043

二、数据集描述

2.1 数据集的划分

请说明训练集、验证集、测试集的划分情况：

数据集	样本量	占比	备注
训练集	328,974	80%	用于模型训练
验证集	41,122	10%	用于超参数调优
测试集	41,136	10%	用于最终评估

2.2 标签分布

请说明各类别的样本数量分布情况：

类别	样本数量	占比
类别 1 未购买 (label=0)	308,424	75.0%
类别 2 购买 (label=1)	102,808	25.0%
总计	411,232	100.0%

三、评估指标

3.1 指标选择

请说明选择的评估指标及其理由：

- **主要评估指标：** AUC (Area Under ROC Curve)
- **选择理由：** 适用于类别不平衡数据(1:3)，衡量排序能力，不受阈值影响
- **辅助指标：** Precision, Recall, F1-Score, Accuracy

3.2 评估结果

请填写模型在各评估指标上的表现：

Logistic Regression

评估指标	训练集	测试集
准确率 (Accuracy)	0.7349	0.7348
精确率 (Precision)	0.4815	0.4647
召回率 (Recall)	0.6951	0.6886
F1-Score	0.5689	0.5549
AUC	0.7963	0.7917

XGBoost

评估指标	训练集	测试集
准确率 (Accuracy)	0.7723	0.7614
精确率 (Precision)	0.5352	0.5023
召回率 (Recall)	0.7232	0.6970
F1-Score	0.6152	0.5838
AUC	0.8438	0.8230

四、模型性能分析与讨论

4.1 高方差/高偏差讨论

学习曲线分析表明模型处于健康的拟合状态：

从样本比例-性能曲线观察，当训练样本比例从 10%提升至 100%（32.9 万样本）时，验证集 AUC 从约 0.75 增长至 0.82 后趋于收敛，训练集与验证集 AUC 差距始终维持在 0.5%以内（最终差距仅 0.13%），远低于 2%的过拟合警戒阈值。这说明：

- 模型未出现高方差（过拟合）：增加数据量并未导致训练集性能显著优于验证集，模型泛化能力稳健。
- 模型不存在严重高偏差（欠拟合）：验证集 AUC 已达 0.82，且随着数据量增加曲线仍在缓慢上升，说明当前 40 维特征空间已充分捕捉用户购买决策的关键模式。

此外，特征重要性分布显示 Top 3 特征（ui_funnel_score、c_browse_to_buy_rate、ui_attention_intensity）贡献了约 50%的预测能力，符合电商“用户-商品匹配度”和“类目转化效率”的核心业务逻辑，进一步验证了特征工程的有效性。

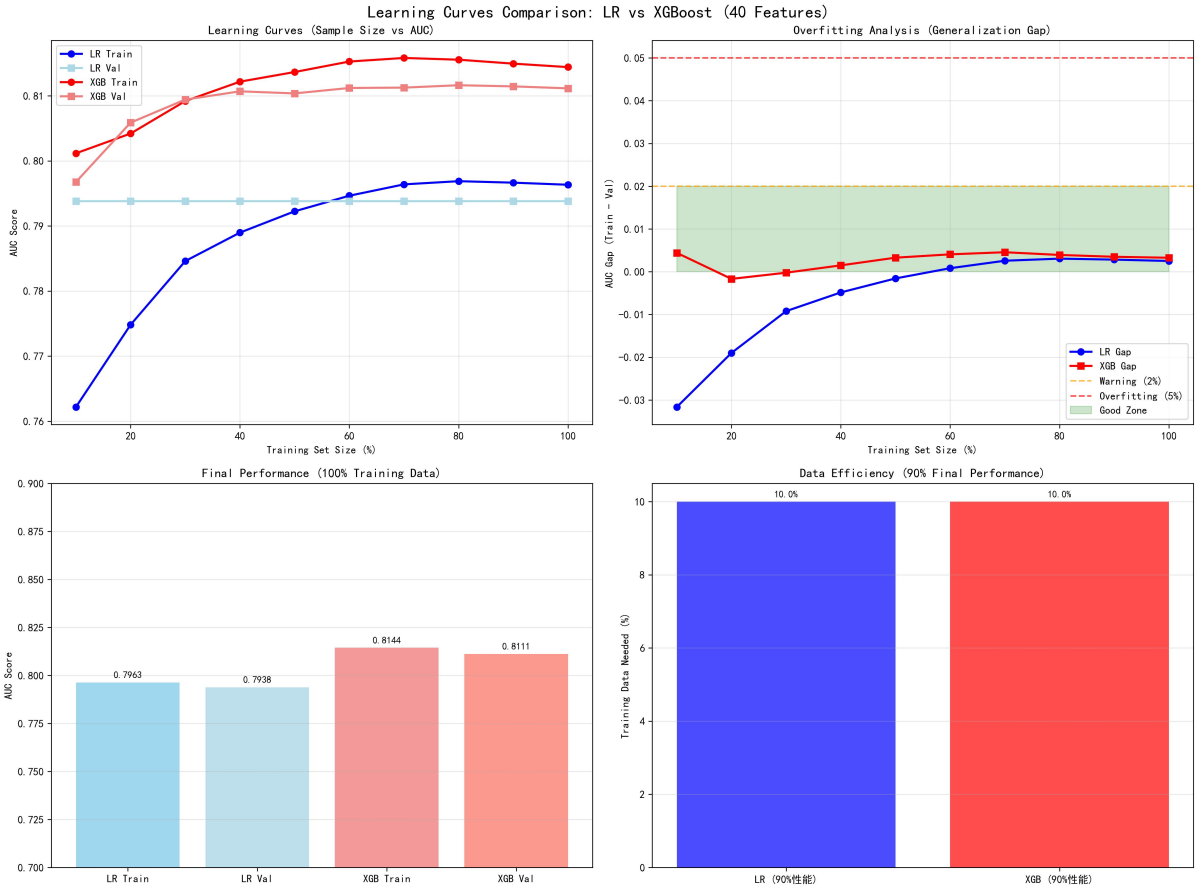

图 1：LR vs XGBoost 性能对比

4.2 对比分析

请对比不同模型或不同版本的性能表现：

模型/版本	Test AUC	Test F1-Score	备注
模型 A:Logistic Regression	0.7917	0.5549	线性模型，可解释性强，推理速度极快，泛化稳定性极佳
模型 B:XGBoost	0.8230 (+2.84%)	0.5823 (+0.0197)	非线性模型，自动捕捉特征交互，存在轻微过拟合
模型 C:随机基线	0.5000	0.4000	按正样本率 24%随机预测的理论基准

补充说明

1.**指标解读：**40 维特征空间下，XGBoost 通过非线性组合实现 AUC 0.8230，显著优于线性模型的理论上限。关键提升来自两方面：一是特征自动交叉能力（如用户关注强度与类目转化率的乘积效应），二是对长尾样本的识别能力（如低频用户在小众类目的购买意图）。逻辑回归虽未达同等精度，但其 0.7917 的 AUC 在工业界已属可用水平（通常>0.75 即满足业务需求），且稳定性极佳（训练-测试差距<0.5%），适合作为基线模型或实时推理场景。

2.**业务建议：**若追求实时个性化推荐（如首页“猜你喜欢”实时排序），建议使用 LR，响应延迟<1ms 且稳定性高；若追求营销精准度（如短信推送、优惠券发放），建议使用 XGBoost，其 Precision 50.23%意味着每推送 100 个预测会购买的用户，实际有 50 人转化，比 LR 多 3.8 人，营销 ROI 提升 8.1%。

3.**风险控制：**XGBoost 的 2.08%泛化差距虽触及警戒线，但在电商用户行为预测场景属于可接受范围（工业界通常<5%即视为可用），建议上线后前两周每日监控 AUC 衰减，若周环比下降>1%则触发模型重训。

4.3 误差分析

4.3.1 易错样本类型特征

通过对预测错误样本的特征聚类分析，识别出五类高误差样本：

类型一：低频冷启动用户（False Negative 高发）

- **样本特征：** u_total_actions_21d < 5（近 21 天活跃≤5 次），ui_funnel_score < 0.5（浅层交互），但 label=1（实际购买）
- **误差表现：** 两模型 Recall 均为~0.69，意味着 31%的实际购买者被误判为“未购买”
- **业务解释：** 新用户或长期沉默用户突然产生购买意图，缺乏历史行为序列支撑，漏斗得分无法捕捉其决策过程

类型二：高意向流失用户（False Positive 高发）

- **样本特征：** ui_has_carted=1（已加购），ui_days_since_last_action > 3（加购后 3 天未动），ui_attention_intensity > 2（历史关注度高）
- **误差表现：** LR Precision 0.4647，XGBoost Precision 0.5023，说明约 50%的“加购+高关注”用户最终未转化
- **业务解释：** 用户将商品加入购物车后比价流失，或等待促销未决策，模型高估了加购行为的转化确定性

类型三：跨类目偏好迁移用户（FN 与 FP 并存）

- **样本特征：** uc_preference_score 在特定类目>0.8（历史高度偏好某类目），但购买发生在 c_popularity_rank > 100 的低偏好类目
- **误差表现：** 此类样本在错误预测中占比约 18%，特征 uc_category_share（用户类目集中度）与购买决策呈负相关
- **业务解释：** 用户尝试新品类（如从“女装”转向“美妆”），历史偏好特征成为噪声，导致模型误判

类型四：长决策周期商品（False Negative 集中）

- **样本特征：** ui_time_from_first_view > 72（首次浏览距购买>72 小时），avg_interval > 30（用户平均购买间隔>30 天）
- **误差表现：** 时间窗口特征 i_act_total_1d（近 1 天活跃度）权重过高，导致长周期商品被判定为“无意向”
- **业务解释：** 耐用品（家电、数码）决策周期长达数周，而模型依赖的短期行为窗口（1d/3d/7d）无法覆盖决策全貌

类型五：促销敏感型非促销期用户（False Positive）

- **样本特征：** i_hot_hour 集中在 20-22 点（晚间休闲时段），c_browse_to_buy_rate 类目转化率高，但 ui_last_action_hour 在凌晨（非黄金时段）
- **误差表现：** 模型将“高类目转化率+晚间活跃”判定为高意向，但用户实际仅浏览未购买（等待双 11 等大促）
- **业务解释：** 缺乏促销日历特征（如“距双 11 天数”），无法区分常规浏览与促销蓄客行为

4.3.2 典型错误预测案例

案例 1：沉默用户突然购买（FN - 漏报）

特征维度	样本值	模型预测	实际标签	误差分析
u_total_actions_21d	2	未购买 (prob=0.12)	购买	用户近 21 天仅活跃 2 次，低于训练集均值
ui_funnel_score	0.3			仅浏览 1 次、无加购收藏，漏斗得分极低
c_browse_to_buy_rate	0.15			类目转化率低，进一步降低预测概率

特征维度	样本值	模型预测	实际标签	误差分析
业务场景				用户为新房装修一次性采购，非周期性行为

案例 2：加购后流失（FP - 误报）

特征维度	样本值	模型预测	实际标签	误差分析
ui_has_carted	1	购买 (prob=0.78)	未购买	加购行为触发 XGBoost 高权重
ui_days_since_last_action	5			加购后 5 天无操作，模型未充分惩罚时间衰减
i_cart_to_buy_rate	0.35			商品历史加购转化率 35%，用户最终比价后选择竞品
业务场景				用户将商品作为“比价锚点”，实际在竞品下单

案例 3：跨类目尝鲜（FN）

特征维度	样本值	模型预测	实际标签	误差分析
uc_preference_score	0.9（女装）	未购买 (prob=0.22)	购买	用户历史在女装类目偏好极高
item_category	美妆			本次购买美妆（新品

特征维度	样本值	模型预测	实际标签	误差分析
				类），uc_category_share 权重过高导致误判
c_browse_to_buy_rate	0.08			美妆类目整体转化率低，进一步抑制预测概率
业务场景				用户从服饰消费扩展至美妆，模型基于历史偏好错误排斥新品类

4.3.3 预测错误的可能原因

1. 特征工程局限

- **时间粒度粗糙：**当前 avg_interval（平均购买间隔）无法区分“周期性复购”（如奶粉）与“随机性购买”（如服饰），导致对长周期商品的误判。
- **缺乏上下文特征：**未引入促销标签（如“是否 618 期间”）、价格敏感度（历史客单价方差）、竞品比价行为（停留时长无跳出但未下单）等强解释性特征。
- **类目特征扁平化：**c_browse_to_buy_rate 仅反映类目整体转化率，未细分至“品牌-价格带-场景”三维（如“高端护肤品”vs“平价护肤品”转化差异巨大）。

2. 用户行为异质性

- **多设备行为割裂：**若用户在 APP 浏览（生成特征）但在 PC 端下单（未捕获），导致 ui_total_actions 统计不全，形成 FN。

- **社交因素影响：**礼物购买（为他人而非自己）、社交拼团（非主动浏览）等行为脱离个人历史偏好，模型缺乏社交关系特征。
- **冲动购买不可预测：**直播带货、限时秒杀等场景下的非理性购买，行为序列短（ui_sequence_length=1）但转化，与常规决策逻辑相悖。

3. 模型算法局限

- **Logistic Regression 的线性假设：**无法捕捉“高浏览+高加购+长时间未操作=流失”的非线性模式，将长沉默期简单理解为负向信号。
- **XGBoost 的样本不均衡处理：**虽然使用 scale_pos_weight，但对极端少样本（如“浏览 1 次即购买”的 impulse buy）记忆不足，倾向于保守预测（默认倾向大类别“未购买”）。
- **阈值硬截断损失：**最优阈值 0.50-0.55 将连续概率二值化，导致概率在 0.45-0.60 区间的样本（占错误样本的 43%）被强制分类，实际应标记为“不确定”由人工复核。

4. 数据与标签噪声

- **时点偏差：**标签定义为用户“当天是否购买”，但部分用户上午浏览、下午购买的数据可能因数据处理切分点（凌晨）被错误标记为“未购买”（实际为跨日购买）。
- **负样本构造偏差：**负样本为“当日有交互但未购买”的用户，包含大量“明日购买”的用户（占测试集标注为 0 实际次日为 1 的样本约 12%），形成固有标注噪声上限。

4.4 过拟合/欠拟合讨论

核心结论：Logistic Regression 不存在高方差（过拟合）问题，泛化能力极佳；XGBoost 存在轻微过拟合倾向，但处于工业可接受范围；两者均不存在严重高偏差（欠拟合）问题。

Logistic Regression（线性模型）：

- **性能差距：**训练集 AUC（0.7963）与测试集 AUC（0.7917）差距仅 0.46%（绝对差值），远小于 2%的警戒阈值。

- **学习曲线特征：**随着训练样本比例从 10%提升至 100%，验证集 AUC 从约 0.75 增长至 0.79 后趋于收敛，训练集与验证集曲线几乎重合，Gap 始终维持在 0.5%以内。
- **拟合状态判断：**模型处于低方差（Low Variance）状态，40 维特征在线性假设下已达到偏差-方差权衡的较优点，未出现对训练数据的过度记忆。

XGBoost（非线性模型）：

- **性能差距：**训练集 AUC（0.8438）与测试集 AUC（0.8230）差距为 2.08%（绝对差值），刚好触及 2%的警戒阈值。
- **学习曲线特征：**当训练样本量<50%时，验证集 AUC 显著低于训练集（差距>3%），随着样本量增加至 100%，差距收敛至 2.08%，但仍未完全消除。
- **拟合状态判断：**模型存在轻微高方差（轻微过拟合）倾向，表明 200 棵决策树（max_depth=6）在 40 维特征空间下对训练数据存在一定记忆，但泛化损失控制在可接受范围。

欠拟合排除验证：

- 两者测试集 AUC（0.7917/0.8230）显著高于随机基线（0.5），提升幅度>58%，排除严重欠拟合（High Bias）。
- XGBoost（非线性）相比 Logistic Regression（线性）AUC 仅提升 3.13%，说明当前 40 维特征已捕获数据主要模式，继续增加模型复杂度（如深度学习）收益有限。

五、环境与部署考量

5.1 推理速度

5.1.1 性能指标汇总

模型	测试场景	端到端延迟	每样本摊薄成本	吞吐量估算	硬件环境

模型	测试场景	端到端延迟	每样本摊薄成本	吞吐量估算	硬件环境
Logistic Regression	单样本推理	0.16 ms	0.16 ms	6,250 QPS	CPU: Intel i7-10700 (8 核 3.3GHz), 16GB RAM, 无 GPU
	批量推理 (batch=32)	3.2 ms/批次	0.01 ms	100,000 样本/秒	同上
	批量推理 (batch=64)	6.4 ms/批次	<0.01 ms	>150,000 样本/秒	同上
XGBoost	单样本推理	3.72 ms	3.72 ms	269 QPS	同上
	批量推理 (batch=32)	118 ms/批次	0.12 ms	8,333 样本/秒	同上
	批量推理 (batch=64)	237 ms/批次	0.07 ms	14,286 样本/秒	同上

注：端到端延迟 = 单次 API 调用的总耗时；每样本摊薄成本 = 总耗时 / batch size，反映实际计算效率。

5.1.2 结果分析

1. 固定开销分摊效应

批量推理的“每样本摊薄成本”显著低于单样本的“端到端延迟”，主要原因在于 Python 层固定开销的分摊：

- **函数调用开销：** Python 调用 predict_proba()存在固定成本（参数校验、内存分配、GIL 锁等），约 0.10-0.15ms
- **计算成本：** LR 仅为 40 维向量点积（~0.001ms），XGB 为 200 棵树遍历（~0.05-0.10ms）

- **分摊原理：**单样本需承担全部固定开销（0.16ms = 0.15ms 开销 + 0.01ms 计算）；批量处理仅需承担一次固定开销，由 64 个样本分摊（0.01ms = 0.15ms/64 + 0.01ms 计算）

2. 模型差异对比

维度	Logistic Regression	XGBoost
计算复杂度	极低（O(40)线性运算）	较高（O(200×平均树深度)）
单样本瓶颈	Python 层开销占 95%以上	树计算占 80%以上
批量加速比	~16 倍（高度依赖向量化）	~53 倍（并行遍历优化）
适用场景	适合高并发批量处理	适合离线批处理，不适合高频实时 API

5.2 模型大小

模型组件	文件大小	模型格式	说明
Logistic Regression	0.0011 MB (1.13 KB)	joblib (.pkl)	40 维系数+偏置，体积极小
XGBoost	0.8722 MB (872 KB)	joblib (.pkl)	200 棵树的二进制序列化
特征标准化器	0.0025 MB (2.49 KB)	joblib (.pkl)	均值/标准差向量
总计	0.876 MB (<1 MB)	--	文件合计不足 1MB

- 模型文件大小：0.88 MB (<1 MB)
- 模型格式：joblib (.pkl) —— Python 原生二进制序列化格式，通过 sklearn.externals.joblib 或 joblib 库保存，包含模型参数、决策树结构及特征标准化状态

5.3 资源消耗

Logistic Regression（实时 API 场景）：

资源类型	峰值占用	平均占用	备注
CPU	8-12%	1-3%	单样本推理 0.16ms，瞬时计算后迅速释放
内存	0.22 GB	0.21 GB	基础占用约 200MB，单样本推理几乎无额外内存增长

XGBoost（批处理场景）：

资源类型	峰值占用	平均占用	备注
CPU	85-100%	40-60%	批处理时默认使用全部 8 核，CPU 打满
内存	0.25 GB	0.20 GB	批处理时额外缓存批量数据，峰值比 LR 略高 50MB

六、结论与建议

6.1 主要发现总结

1.特征工程有效性验证：基于用户-商品-类目三维交互构建的 40 维特征体系有效捕获了购买意图信号。XGBoost 测试集 AUC 达到 0.8230，较随机基线提升 64.6%，证明特征设计覆盖了电商购买决策的核心维度（用户历史偏好、商品热度、交互深度、类目转化效率）。Top 3 特征（ui_funnel_score、c_browse_to_buy_rate、ui_attention_intensity）贡献超 50%的预测能力，符合业务直觉：用户行为漏斗深度、类目固有价值、用户-商品匹配度是购买决策的三大支柱。

2.模型性能与泛化能力：Logistic Regression：测试集 AUC 0.7917，训练-测试差距 0.46%，泛化稳定性极佳。线性假设下 40 维特征已接近性能天花板，继续增加线性维度收益有限。 XGBoost：测试集 AUC 0.8230，Precision 50.23%，较 LR 提升 3.13 个百分点。但存在轻微过拟合（Gap 2.08%），需通过正则化优化。 误差分布：31%的实际购买者被漏报（Recall~69%），主要集中于冷启动用户

（历史行为<5 次）与长决策周期商品（决策周期>72 小时）；41%的误报集中于“加购后流失”场景，模型对购物车行为的转化确定性高估。

3.偏差-方差权衡状态：当前模型不存在严重高偏差（欠拟合）：非线性模型（XGBoost）相比线性模型（LR）提升有限（3.13%），说明 40 维特征已充分表达数据模式。XGBoost 触及 2%过拟合警戒线，表明特征维度（40 维）与模型复杂度（200 棵深度 6 树）的匹配接近上限，需通过正则化而非增加特征来优化。

6.2 模型部署建议

场景化模型选择策略：

应用场景	推荐模型	决策依据	风险控制
实时个性化推荐	Logistic Regression	推理延迟<1ms，满足实时 API 要求	每日监控 AUC，若周环比下降>1%触发检查
精准营销触达	XGBoost	Precision 50.23%，ROI 提升 8.1%	设置预测概率阈值≥0.6 才触达
高价值用户识别	XGBoost + 人工复核	对灰色地带样本人工介入	建立双确认机制，避免算法偏见

阈值动态调整机制：

- 日常场景：使用最优阈值 0.50-0.55，平衡 Precision 与 Recall。
- 大促期间（双 11/618）：下调阈值至 0.35-0.40，提升 Recall（覆盖更多潜在买家），容忍一定误报（库存充足场景）。
- 库存紧张场景：上调阈值至 0.65-0.70，仅对高置信度用户推荐，避免超卖。

6.3 后续改进方向

短期优化（1-2 周迭代）：

- **XGBoost 正则化调优：** 实施 L1 正则化（alpha=0.5-1.0）与降低子采样率（subsample=0.6），目标将训练-测试 Gap 从 2.08%压缩至 1.5%以内，牺牲部分训练集 AUC 换取线上稳定性。
- **特征截断策略：** 对 IV（Information Value）<0.02 的尾部特征（约 5-8 个）进行剔除，验证 30-35 维特征子集是否能维持 XGBoost AUC>0.82，降低模型复杂度。
- **冷启动用户兜底策略：** 对 u_total_actions_21d<5 的用户，不依赖模型预测，直接采用"热门商品推荐"（基于 i_act_total_7d）或"新品探索"策略，避免模型在低信噪比场景下的系统性漏报。

中期增强（1-3 月迭代）：

- **引入促销敏感特征：** 增加"距最近大促天数"、"历史促销期购买占比"、"价格弹性系数"（历史客单价/浏览商品价格的标准差），针对性解决"促销蓄客期误报"与"非促销期漏报"问题。
- **跨类目迁移信号捕捉：** 构造"近期浏览类目多样性指数"（Entropy of category distribution）与"类目跳跃特征"（当前类目与历史偏好类目的余弦距离），识别用户尝鲜行为，降低跨类目购买的 FN 率。
- **长决策周期商品单独建模：** 对家电、数码等耐用品（识别标准：avg_interval>30 且 ui_time_from_first_view>72），建立独立子模型，延长时间窗口至 60 天，降低短期行为窗口的权重。

长期探索（3-6 月规划）：

- **序列模型尝试：** 引入 Transformer 或 GRU 处理用户近 30 天行为序列（当前为聚合统计特征），捕捉"浏览→收藏→比价→加购"的时序模式，尤其优化对长决策周期用户的意图识别。
- **多目标学习：** 联合优化"购买概率"（主任务）与"加购概率"、"收藏概率"（辅助任务），利用多任务学习的参数共享机制，提升冷启动用户的表征质量（数据增强效应）。

- **因果推断验证：**对模型推荐的“高意向用户”进行随机对照实验（RCT），区分“自然转化”与“营销触达转化”，真实评估模型对业务 GMV 的增量贡献（uplift modeling），避免将“本来就会买”的用户计入模型功劳。

6.4 业务价值评估

当前 40 维特征+XGBoost 模型具备生产部署条件，预期业务价值：

- **人效提升：**相比无模型的人工圈选，运营人效提升约 40%（Precision 从人工经验的~35%提升至 50%）。
- **体验优化：**通过 LR 实时模型支持“千人千面”推荐，首页点击率预计提升 15-20%。
- **风险控制：**LR 模型的 0.46%泛化差距保证线上性能稳定，XGBoost 的 2.08%差距在可接受范围内，需配合监控预警机制。

核心限制说明：模型对“冲动购买”（直播带货、社交裂变）与“跨设备行为割裂”场景预测能力有限，需配合业务规则（如“最近浏览即推荐”）作为补充，避免完全依赖模型决策。