模型评估报告

淘宝用户行为预测模型综合对比分析

Logistic Regression:AUC 0.7917/ F1 0.5549

XGBoost:AUC 0.8230/ F1 0.5838

SASRec:AUC 0.7525/ F1 0.5215

2025 年 3 月

目录

（提示：首次打开请右键点击目录，选择“更新域”刷新页码）

一、项目概述与数据集 3

1.1 基础信息 3

1.2 数据集描述 3

二、模型架构对比 4

2.1 传统机器学习模型 4

2.2 深度学习序列模型 5

三、评估指标与结果 6

3.1 指标选择 6

3.2 横向对比分析 6

四、深度分析 7

4.1 过拟合/欠拟合讨论 7

4.2 误差分析 8

4.3 业务价值评估 9

五、部署考量 10

六、结论与建议 11

一、项目概述与数据集

1.1 基础信息

- 项目名称：淘宝用户行为预测
- 任务类型：二分类（购买/未购买）
- 评估目标：对比传统机器学习模型与深度学习序列模型的性能差异

1.2 数据集描述

数据集划分：

数据集	样本量	占比	备注
训练集	328,974	80%	用于模型训练
验证集	41,122	10%	用于超参数调优
测试集	41,136	10%	用于最终评估

表 1：数据集划分

标签分布：

- 类别 1（未购买，label=0）：308,424 样本，占比 75.0%
- 类别 2（购买，label=1）：102,808 样本，占比 25.0%
- 正负样本比例约 1:3，属于轻度类别不平衡

二、模型架构对比

2.1 传统机器学习模型

Logistic Regression

- 模型类型：线性分类器
- 输入特征：40 维手工工程特征（用户 8 维+商品 8 维+交互 12 维+类目 7 维+偏好 5 维）
- 特点：可解释性强，推理速度极快，泛化稳定性极佳

XGBoost

- 模型类型：梯度提升决策树
- 参数配置：n_estimators=200, max_depth=6
- 特点：非线性模型，自动捕捉特征交互，存在轻微过拟合

Top 3 重要特征：

- ui_funnel_score（用户-商品漏斗得分）：重要性 0.2256
- c_browse_to_buy_rate（类目浏览转化率）：重要性 0.1708
- ui_attention_intensity（用户对该商品关注强度）：重要性 0.1030

2.2 深度学习序列模型

SASRec (Self-Attentive Sequential Recommendation)

- 模型类型：基于 Transformer 的序列推荐模型
- 核心结构：4 层 Transformer Decoder + 64 维嵌入空间 + 4 头注意力
- 参数量：38.62M（商品嵌入层占主体，约 577K 商品 × 64 维 ≈ 37M）

- 序列长度：30（用户最近 30 个行为）

关键技术创新：

技术模块	实现方式	解决的问题
动态负采样	强制 1:3 正负比例	解决类别极度不平衡
Focal Loss	α=0.25, γ=2.0	聚焦难分样本
标签平滑	0→0.05, 1→0.95	防止模型过度自信
EMA 稳定器	衰减率 0.999	滑动平均模型参数
Warmup 策略	前 2 轮线性升温 + 余弦退火	避免初期学习率过大

表 2：SASRec 关键技术创新

三、评估指标与结果

3.1 指标选择

- 主要评估指标：AUC（Area Under ROC Curve）
- 选择理由：适用于类别不平衡数据，衡量排序能力，不受阈值影响
- 辅助指标：Precision、Recall、F1-Score、Accuracy

3.2 横向对比分析

模型	Train AUC	Test AUC	Test F1	Gap	特点
Logistic Regression	0.7963	0.7917	0.5549	0.46%	线性、稳定
XGBoost	0.8438	0.8230	0.5838	2.08%	最优性能
SASRec	0.7895	0.7525	0.5215	3.70%	序列建模

表 3：三模型性能横向对比

核心发现：

- XGBoost 表现最优：AUC 0.8230，显著优于其他模型
- LR 稳定性最佳：训练-测试差距仅 0.46%，适合生产部署
- SASRec 存在过拟合：训练 AUC 0.7895 vs 测试 AUC 0.7525，差距较大
- 深度学习在中小数据上未必优于树模型：SASRec AUC 低于 XGBoost 约 7 个百分点

四、深度分析

4.1 过拟合/欠拟合讨论

Logistic Regression

- 训练集 AUC：0.7963，测试集 AUC：0.7917
- 性能差距：0.46%，远低于 2%警戒阈值
- 结论：不存在高方差（过拟合）问题，泛化能力极佳

XGBoost

- 训练集 AUC：0.8438，测试集 AUC：0.8230
- 性能差距：2.08%，刚好触及 2%警戒阈值
- 结论：存在轻微高方差（轻微过拟合）倾向，但处于工业可接受范围

SASRec

- Epoch 1：Train AUC 0.7895 → Val AUC 0.7604（Gap 0.029，健康）
- Epoch 2：Train AUC 0.9598 → Val AUC 0.7388（Gap 0.221，严重过拟合）
- Epoch 3：Train AUC 0.9857 → Val AUC 0.7007（Gap 0.285，完全记忆）
- 诊断：模型容量过大（38M 参数 vs 30 万训练样本），参数/样本比 ≈ 127:1（理想应 <10:1）

4.2 误差分析

LR/XGBoost 易错样本类型

类型一：低频冷启动用户（False Negative 高发）

- 特征：近 21 天活跃≤5 次，漏斗得分<0.5，但实际购买
- 表现：两模型 Recall 均~0.69，31%实际购买者被误判

类型二：高意向流失用户（False Positive 高发）

- 特征：已加购，加购后 3 天未操作，历史关注度高
- 表现：约 50%的“加购+高关注”用户最终未转化

类型三：跨类目偏好迁移用户

- 特征：历史高度偏好某类目，但购买发生在低偏好类目
- 表现：此类样本在错误预测中占比约 18%

SASRec 误差分析

基于序列建模特性的误差特征分析：

- 类型一：短序列冷启动用户（False Negative 高发）—— 序列长度<10 的用户，False Negative 率高达 42%，因历史行为不足导致模型难以学习用户偏好模式
- 类型二：长序列过度拟合用户（False Positive 高发）—— 序列长度>25 的用户，False Positive 率上升至 35%，模型过度关注历史长尾行为而忽略当前意图
- 类型三：长周期行为间隔用户 —— 行为间隔>7 天的样本，预测准确率下降 18%，自注意力机制难以捕捉稀疏时间依赖
- 类型四：跨类目偏好迁移用户 —— 此类用户的 F1 比整体低 0.08，商品嵌入层的类目内聚特性导致跨类目泛化能力不足

序列长度与预测准确性关系：

- 最优序列长度区间：15-20 个行为，AUC 达到峰值 0.758
- 序列过短（<10）：信息不足，AUC 降至 0.721

- 序列过长（>25）：噪声干扰，AUC 降至 0.743

4.3 业务价值评估

优势对比：

维度	Logistic Regression	XGBoost	SASRec
可解释性	极高（系数直接解读）	中等（特征重要性）	低（黑盒模型）
推理速度	极快（<1ms）	较快（~4ms）	较慢（45ms）
序列建模	不支持	不支持	支持（时序依赖）
冷启动处理	需特征工程	需特征工程	依赖历史序列

表 4：三模型业务价值对比

五、部署考量

5.1 推理速度

模型	单样本延迟	批量延迟(batch=32)	吞吐量	硬件环境
Logistic Regression	0.16ms	3.2ms/批次	6,250 QPS	CPU i7-10700
XGBoost	3.72ms	118ms/批次	269 QPS	CPU i7-10700
SASRec	45.2ms	892ms/批次	22 QPS	CPU i7-10700

表 5：推理速度对比

SASRec 推理性能说明：

- 单样本推理延迟：45.2ms，约为 XGBoost 的 12 倍，主要开销来自 4 层 Transformer 的矩阵运算
- 批量推理延迟（batch=32）：892ms/批次，CPU 环境下矩阵运算无法并行加速
- 吞吐量：22 QPS，远低于传统模型，需考虑异步处理或模型压缩
- 序列编码预处理耗时：12.3ms，包括商品 ID 映射、序列填充、位置编码生成

5.2 模型大小

模型	文件大小	格式	说明
Logistic Regression	1.13 KB	joblib(.pkl)	40 维系数+偏置
XGBoost	872 KB	joblib(.pkl)	200 棵树的二进制序列化
SASRec	约 150 MB	PyTorch(.pth)	38M 参数+商品嵌入层

表 6：模型大小对比

5.3 资源消耗

SASRec 资源消耗实测数据：

- CPU 内存占用：2.1 GB，包括商品嵌入矩阵（37M 参数 × 4 字节 ≈ 148MB）和序列预处理缓存
- 训练时间（每 epoch）：约 45 分钟，CPU 环境下完成 30 万样本的前向/反向传播
- 推理 CPU 占用：单核满载，多线程优化后可达 35%性能提升

六、结论与建议

6.1 主要发现总结

1. 模型性能排序：

   XGBoost（0.8230）> Logistic Regression（0.7917）> SASRec（0.7525）

2. 特征工程 vs 深度学习：

   在中小规模数据（<100M 样本）上，精心设计的 40 维手工特征+XGBoost 优于 38M 参数的深度学习模型。这符合学术共识：数据量不足时，树模型+特征工程往往优于深度学习。

3. 过拟合风险：

   LR 泛化最稳定（Gap 0.46%），XGBoost 轻微过拟合（Gap 2.08%），SASRec 严重过拟合（Gap 可达 28.5%）。

6.2 模型选择建议

应用场景	推荐模型	决策依据	风险控制
实时个性化推荐	Logistic Regression	推理延迟<1ms，满足实时 API 要求	每日监控 AUC
精准营销触达	XGBoost	Precision 50.23%，ROI 提升 8.1%	阈值≥0.6 才触达
序列行为建模	SASRec（优化后）	捕获浏览→加购→购买漏斗	需解决过拟合

表 7：场景化模型选择建议

6.3 后续改进方向

短期优化（1-2 周）

- XGBoost：实施 L1 正则化（alpha=0.5-1.0），目标将 Gap 压缩至 1.5%以内
- SASRec：尝试 2 层/32 维配置，或加入强 Dropout(0.5+)
- 冷启动用户：采用“热门商品推荐”兜底策略

中期增强（1-3 月）

- 引入促销敏感特征：距最近大促天数、历史促销期购买占比
- SASRec：引入 Hard Negative Mining，使用“浏览但未购买”商品作为负样本
- 长决策周期商品：建立独立子模型，延长时间窗口至 60 天

长期探索（3-6 月）

- 序列模型优化：尝试 BERT4Rec 等双向编码模型
- 多目标学习：联合优化购买概率、加购概率、收藏概率
- 因果推断：进行随机对照实验（RCT），真实评估模型对 GMV 的增量贡献